

Etapa 2: Conociendo los datos

Miranda Cornejo Ahuja

Department of Data Science and Mathematics
Instituto Tecnológico de Estudios Superiores de Monterrey
Monterrey, México
a01571668@tec.mx

Leonardo Albarrán Valdés

Department of Data Science and Mathematics
Instituto Tecnológico de Estudios Superiores de Monterrey
Monterrey, México
a01571750@tec.mx

Natalia Cervantes González

Department of Data Science and Mathematics
Instituto Tecnológico de Estudios Superiores de Monterrey
Monterrey, México
a00838465@tec.mx

Hugo Jaime Valdés

Department of Data Science and Mathematics
Instituto Tecnológico de Estudios Superiores de Monterrey
Monterrey, México
a01384039@tec.mx

I. COMPRENSIÓN DE LOS DATOS

A. Objetivo

La EGADE Business School, del Tecnológico de Monterrey, encontró, en que la calidad del aire de la Zona Metropolitana de Monterrey se encontraba dentro de las peores del país, particularmente cuando la refinería de Cadereyta está en operación: no tan solo por sus altas emisiones de PM_{2.5} y SO₂, que cuentan con un impacto negativo en la salud de la población, sino porque la refinería de Cadereyta produce 5 veces más contaminantes que las 8 plantas de industria privada en la ciudad. Además, estas instalaciones consumen alrededor de 130 litros de agua potable por segundo, que en entorno propenso a sequía que la ciudad presenta recientemente, no es precisamente alentador; estos datos, acompañados de su ineficiencia en utilidad financiera, ponen a la refinería de Cadereyta en posición de ser reconsiderada como una industria mantenible, ya que contamina, consume recursos y pierde dinero cada año.

Es por las razones anteriores que, originalmente, se definió el objetivo general de esta investigación como cuantificar la contribución de la Refinería de Cadereyta a las concentraciones de PM_{2.5}, PM₁₀, NO₂, NO_x, SO₂ y CO dentro de la Zona Metropolitana de Monterrey, tomando en cuenta la meteorología y el tráfico, esto para cumplir el objetivo particular de evaluar cómo la meteorología y el tráfico modula la contribución de la refinería. Sin embargo, después de reconsiderar la información disponible, el tiempo dado para terminar esta investigación y las pruebas estadísticas disponibles, se decidió reformular el objetivo para que, fuera: Determinar qué patrones de contaminantes de la Refinería de Cadereyta que son determinantes en la calidad del aire de la Zona Metropolitana de Monterrey.

B. Técnicas estadísticas

Este objetivo será contestado con el uso de la prueba estadística de Análisis de Componentes Principales (PCA), en

comparación a un Análisis factorial de Máxima Verosimilitud; estas pruebas, aplicadas sobre las concentraciones de contaminantes atmosféricos de la zona, permitirán identificar combinaciones de contaminantes que puedan ser representativos del impacto del uso de la Refinería de Cadereyta, además, son un tipo de análisis que reducirá la multicolinealidad de variables correlacionadas para mejor visualización, comparación y clasificación posterior al estudio.

C. Descripción de variables

Decidimos que usaremos todas las variables, principalmente para lograr identificar todos los posibles patrones de contaminantes, meteorológicos y espaciales. Justo estos tres grupos de variables serán los que permitirán identificar los patrones de contaminación asociados con la operación de la Refinería de Cadereyta:

- **Contaminantes:** Estas variables representan los contaminantes medidos por las SIMA en la Zona Metropolitana de Monterrey. Son fundamentales para evaluar la composición y concentración de la contaminación atmosférica. CO, NO, NO₂, NO_x, SO₂, O₃, PM₁₀, PM_{2.5}.

- **Meteorológicas:** Estas variables modulan la dispersión, transporte y transformación de los contaminantes. Su análisis permite comprender cómo las condiciones del clima influyen en los patrones de concentración. TOUT, RH, PRS, WSR, WDR, wind_u, wind_v, RAINF, SR, photo_index, season.

- **Espaciales (Estación):** Esta variable permite ubicar geográficamente los datos y analizar diferencias espaciales entre zonas dentro de la Zona Metropolitana de Monterrey.

D. Continuidad

Durante el proceso de preparación de los datos del sistema SIMA para el análisis del impacto de la refinería de Cadereyta en la contaminación del área metropolitana de Monterrey, se realizaron varias modificaciones orientadas a preservar la integridad y el comportamiento real de las mediciones. En primer lugar, se reemplazó el tratamiento estadístico de valores atípicos basado en percentiles por una limpieza

sustentada en los rangos de operación oficiales del SIMA, eliminando únicamente los valores físicamente imposibles o fuera de los límites instrumentales. De esta forma, se evita alterar concentraciones reales extremas que reflejan episodios ambientales genuinos.

En cuanto a los valores faltantes, se decidió conservar los NaN en lugar de imputarlos, para no introducir sesgos ni modificar la estructura temporal de los datos, manteniendo así la variabilidad natural de las series. También se eliminó la discretización de contaminantes, conservando los valores continuos originales para permitir un análisis más detallado y preciso.

Se mantuvieron las variables temporales derivadas de `add_time_features`, útiles para distinguir el comportamiento continuo de la refinería frente a las variaciones semanales del tráfico urbano, y se conservaron los componentes del viento (U y V), fundamentales para identificar el transporte de contaminantes desde Cadereyta hacia la ciudad. En las variables químicas derivadas, se retuvo únicamente el índice fotoquímico (`photo_index`), empleado para evaluar la capacidad de formación de ozono y la reactividad atmosférica vinculada a las emisiones de la refinería, descartando los cálculos de NO_X redundantes y el indicador de lluvia.

En conjunto, estas decisiones consolidan una base de datos físicamente coherente, sin transformaciones que distorsionen los valores reales, permitiendo analizar con mayor precisión la influencia espacial, temporal y química de la refinería de Cadereyta sobre la calidad del aire en Monterrey.

II. PARTE 2. COMPRENSIÓN Y PREPARACIÓN DE DATOS

A. Comprensión de los datos

- Número de variables: 21
- Dimensión de dataset: (328070, 21)
- Sin datos duplicados
- Imputación: media móvil e interpolación

B. Exploración de datos

Medidas estadísticas variables cuantitativas:

C. Medidas de tendencia central tabla

D. Medidas de dispersión tabla

Medidas estadísticas variables cualitativas:

E. Tabla de distribución de frecuencias

F. Mediana. Escala Ordinal

- Mediana numérica: 5.0
- Mediana ordinal: NO (Noroeste)

Variables	Descripción	Tipo	Valor posible
Fecha y Hora	Fecha y hora	datetime64[ns]	Fechas y horas dentro del rango
CO(ppm)	Monóxido de carbono	float64	Valores numéricos
NO(ppb)	Monóxido de nitrógeno	float64	Valores numéricos
NO2(ppb)	Dióxido de nitrógeno	float64	Valores numéricos
NOX(ppb)	Suma de NO + NO2	float64	Valores numéricos
O3(ppb)	Ozono	float64	Valores numéricos
PM10(ug/m3)	Material particulado menor a 10 micrómetros	float64	Valores numéricos
PM2.5(ug/m3)	Material particulado menor a 2.5 micrómetros	float64	Valores numéricos
PRS(mmHg)	Presión atmosférica	float64	Valores numéricos
RAINF(mm/h)	Precipitación	float64	Números >= 0
RH(%)	Humedad relativa	float64	Entre 0 y 100
SO2(ppb)	Dióxido de azufre	float64	Valores numéricos
SR(kW/m2)	Radiación Solar	float64	Valores >= 0
TOUT(°C)	Temperatura	float64	Negativo o positivo
WSR(km/h)	Velocidad del viento	float64	>= 0
WDR(azimutal)	Dirección del viento	float64	Entre 0 y 360
Estacion	Ubicación	object	Abreviatura de estaciones de monitoreo
season	Temporada estacional	int64	0,1,2,3 para cada temporada
wind_u	componente este-oeste (eje X)	float64	Si U es positivo indica que el viento sopla hacia el este y si es negativo indica que sopla al oeste
wind_v	componente norte-sur	float64	Positivo: Norte, Negativo: Sur
photo_index	intensidad de procesos fotoquímicos	float64	Valores numéricos

Fig. 1. Descripción de variables

Medidas de tendencia central:			
Variables	Promedio	Mediana	Moda
CO	0.204490	0.000000	-0.336364
NO	0.782599	0.000000	-0.275862
NO2	0.236453	0.000000	-0.423077
NOX	0.425515	0.000000	-0.413793
O3	0.148268	0.000000	-0.5
PM10	0.250481	0.000000	-0.175
PM2.5	0.228727	0.000000	-0.394928
PRS	0.066015	0.000000	1.233333
RAINF	0.014525	0.000000	0.0
RH	-0.041783	0.000000	0.542857
SO2	0.375173	0.000000	-0.5
SR	0.603940	0.000000	-0.00885
TOUT	-0.073159	0.000000	0.095238
WSR	0.103424	0.000000	-0.878788
WDR	0.186228	0.000000	-0.159091
season	1.371421	1.000000	1
wind_u	-0.985752	-1.032146	-2.44389
wind_v	0.100097	0.041686	-0.387942
photo_index	0.442028	0.002941	1.454260e-11

Fig. 2. Medidas de Tendencia Central

Medidas de dispersión:			
Variables	Rango	Varianza	Desviación Estándar
CO	13.909091	0.636566	0.797851
NO	57.413793	5.069373	2.251527
NO2	12.153846	0.722488	0.849993
NOX	24.605911	1.767355	1.329419
O3	7.645833	0.645893	0.803674
PM10	24.950000	1.116604	1.056695
PM2.5	60.295894	1.031697	1.015725
PRS	4.375000	0.581234	0.762387
RAINF	67.800000	0.199224	0.446346
RH	2.857143	0.385208	0.620651
SO2	202.100000	4.314291	2.077087
SR	5.539823	0.926270	0.962429
TOUT	4.880952	0.533209	0.730212
WSR	6.030303	0.498986	0.706390
WDR	2.719697	0.524834	0.724455
season	3.000000	1.158274	1.076231
wind_u	21.251670	3.334609	1.826091
wind_v	20.048931	2.654146	1.629155
photo_index	54.560000	1.124535	1.060441

Fig. 3. Medidas de Dispersión

Estación	Frecuencia	Estación	Frecuencia
Sheet 1	64959	NTE	17540
CE	17542	NO2	17540
NO3	17542	NE3	17540
NE	17542	NTE2	17540
SE	17542	SE3	17540
SO	17542	SUR	17540
NO	17541	SE2	17540
NE2	17540	SO2	17540

Fig. 4. Frecuencias




Fig. 5. Boxplot de variables cuantitativas




Fig. 6. Mapa de calor

G. Exploración usando herramientas de visualización

Outliers:

- CO: 7762 outliers
- NO: 33759 outliers
- NO2: 10787 outliers
- NOX: 25131 outliers
- O3: 9065 outliers
- PM10: 15700 outliers
- PM2.5: 9660 outliers
- PRS: 15700 outliers
- RAINF: 9660 outliers
- RH: 0 outliers
- SO2: 21185 outliers
- SR: 22911 outliers
- TOUT: 1652 outliers
- WSR: 2879 outliers
- WDR: 0 outliers

- season: 0 outliers
- wind_u: 3151 outliers
- wind_v: 5159 outliers
- photo_index: 49384 outliers

H. Histogramas

Los histogramas realizados para todas las variables cuantitativas, identifican de igual manera si se tiene forma simétrica o asimétrica, todos los histogramas de todas las variables cuantitativas son visibles en el código y en el anexo de "Gráficas", al igual que sus respectivas distribuciones con respecto al skewness.




Fig. 7. Gráfica de barras Estación




Fig. 8. Diagrama de pastel Estación

I. Distribución de los datos. Variable Estación

III. CONCLUSIÓN

Hasta este punto se ha logrado consolidar una base de datos completa, limpia y coherente, integrando los registros del SIMA para los años 2023–2025 y asegurando que las variables mantengan su validez física y ambiental. El conjunto de datos refleja fielmente la dinámica de los contaminantes criterio, las condiciones meteorológicas y las diferencias espaciales entre estaciones, permitiendo así un análisis más robusto del impacto potencial de la Refinería de Cadereyta en la calidad del aire de la Zona Metropolitana de Monterrey. La comprensión y preparación de los datos se encuentran completadas: se eliminaron valores imposibles, se conservaron las mediciones genuinas de episodios críticos y se definieron correctamente las variables

relevantes (contaminantes, meteorológicas y espaciales). Los análisis descriptivos iniciales permitieron observar la alta variabilidad de los contaminantes y su posible relación con factores meteorológicos como el viento o la radiación solar.

Aún falta realizar la fase de modelado estadístico, donde se aplicarán el Análisis de Componentes Principales (PCA) y el Análisis Factorial por Máxima Verosimilitud (MLF) para identificar los patrones dominantes de contaminación y las combinaciones de variables que explican mejor las variaciones observadas. Posteriormente, se prevé realizar una interpretación ambiental de los componentes principales, vinculados con las fuentes emisoras y las condiciones atmosféricas.

El camino a seguir consiste en validar los resultados obtenidos, comparar ambos métodos estadísticos y analizar su consistencia con la información meteorológica y espacial. Las preguntas ¿Qué conjunto de contaminantes explica en mayor medida la variabilidad total de la contaminación atmosférica? ¿Cómo influyen la dirección y velocidad del viento en la propagación de los contaminantes desde la refinería? ¿Existen diferencias significativas entre estaciones que puedan atribuirse a la proximidad con Cadereyta? detonan la siguiente etapa del proyecto, orientada a obtener conclusiones cuantitativas y ambientalmente significativas sobre el papel de la Refinería de Cadereyta en la calidad del aire regionmontano.

IV. ANEXOS

Google Colab.
GitHub.
Gráficos

REFERENCES

- [1] Sistema Integral de Monitoreo Ambiental [SIMA] Nuevo León. (s/f). Gob.mx. Recuperado el 2 de octubre de 2025, de <https://aire.nl.gob.mx/>
- [2] Calidad del aire ambiente (exterior) y salud. (s/f). Who.int. Recuperado el 2 de octubre de 2025, de [https://www.who.int/es/news-room/fact-sheets/detail/ambient-\(outdoor\)-air-quality-and-health](https://www.who.int/es/news-room/fact-sheets/detail/ambient-(outdoor)-air-quality-and-health)