

Evaluación del impacto de la Refinería en la calidad del aire del área metropolitana mediante técnicas estadísticas

Miranda Cornejo Ahuja

Department of Data Science and Mathematics
Instituto Tecnológico de Estudios Superiores de Monterrey
Monterrey, México
a01571668@tec.mx
Equipo 1

Leonardo Albarrán Valdés

Department of Data Science and Mathematics
Instituto Tecnológico de Estudios Superiores de Monterrey
Monterrey, México
a01571750@tec.mx
Equipo 1

Natalia Cervantes González

Department of Data Science and Mathematics
Instituto Tecnológico de Estudios Superiores de Monterrey
Monterrey, México
a00838465@tec.mx
Equipo 1

Hugo Jaime Valdés

Department of Data Science and Mathematics
Instituto Tecnológico de Estudios Superiores de Monterrey
Monterrey, México
a01384039@tec.mx
Equipo 1

I. OBJETIVO

Cuando se discute la calidad del aire en la Zona Metropolitana de Monterrey, es imposible no traer a la mesa la constante y pesada aportación de la industria a los contaminantes presentes hoy en día en dicha área; es por eso que el objetivo de esta investigación estuvo, desde un inicio, determinado a explorar la presencia de importantes instalaciones como la Refinería de Cadereyta y sus contribuciones a los datos que SIMA proporcionó para trabajar en el reto de esta clase.

Primeramente, el objetivo se estableció como cuantificar la contribución de la Refinería de Cadereyta a las concentraciones de contaminantes dentro de la Zona Metropolitana de Monterrey, tomando en cuenta la meteorología y el tráfico, esto para cumplir el objetivo particular de evaluar cómo la meteorología y el tráfico modula la contribución de la Refinería. Este cumplió el propósito de ser un objetivo de partida desde el cual se pudo hacer correcciones y diversas propuestas, explorando el qué se quería obtener como respuesta y conclusión a esta investigación; en un final, se optó por determinar el objetivo de la siguiente manera: Analizar el impacto de los contaminantes expulsados de las instalaciones de la Refinería de Cadereyta a sus estaciones meteorológicas aledañas, con el propósito de evaluar en qué medida los datos de la principal zona industrial de la zona explica la variabilidad y los niveles de contaminación ambiental de sus alrededores en la Zona Metropolitana de Monterrey.

Este objetivo es pertinente y trascendente debido a los recurrentes episodios de mala calidad del aire que experimenta esta área, que tienen efectos nocivos en la salud pública y, por consiguiente, en la calidad de vida de sus habitantes; además de buscar conclusiones para la investigación como tal, se busca proporcionar información cuantitativa para la discusión pública relacionada con la presencia de la industria y sus efectos en la calidad del aire a su alrededor, aumentando las posibilidades de anticipar y mitigar posibles futuros efectos nocivos a la salud pública.

II. TÉCNICAS ESTADÍSTICAS

Con el objetivo establecido, se eligió como primera técnica estadística a usar fue la regresión lineal múltiple, que se usó con el objetivo de modelar las relaciones lineales entre una variable objetivo con las demás variables y obtener un diagnóstico claro que, junto con técnicas de regularización de datos, pueden mejorar el ajuste y resultados del modelo; en este caso específico se construyó una regresión por contaminante para respetar la naturaleza específica de cada uno, mejorando la validez de los resultados generales.

Como segunda técnica estadística, se decidió utilizar el análisis factorial, es una técnica estadística que pone en manifiesto las relaciones entre las variables y nos ayuda a comprender los datos que se modelan. Esta herramienta permite investigar conceptos que no son fáciles de medir directamente, esto mediante diferentes tipos de métodos, tales como el análisis de componentes principales, factorización de imágenes, máxima similitud, mínimos residuos. Para poder

realizar un análisis factorial, se debe definir el objetivo, se hizo la selección de las variables relevantes para el análisis, se selecciona el tipo de análisis a realizar ya sea AFE (análisis factorial exploratorio) o AFC (análisis factorial confirmatorio), después se deben preparar los datos correspondientes para el análisis factorial. Una vez teniendo los datos preparados, se utiliza un software estadístico para poder identificar y explorar los factores subyacentes que expliquen la varianza observada en las variables. Después de obtener los resultados, es muy importante interpretar y comprender cómo las variables se agrupan y contribuyen a un factor identificado. En resumen, el análisis factorial es una herramienta indispensable para comprender la complejidad de los conjuntos de datos extensos en investigaciones, nos informa sobre la toma de decisiones estratégicas con evidencias y la comprensión del comportamiento y tendencias.

III. DESCRIPCIÓN DE SEPARACIÓN DE DATOS

Para el propósito planteado, se decidió realizar una división en distintas bases de datos provenientes de nuestra base de datos principal con la finalidad de evaluar específicamente las estaciones meteorológicas de la Refinería de Cadereyta y sus aledaños, en este caso zona Sureste 2 (Municipio de Juárez) y Sureste (Municipio de Guadalupe). Se realizó esta separación de datos en base a las zonas a analizar, conservando las variables. Se trabajó con 3 variables a analizar: SO₂, PM₁₀, PM_{2.5}, esta elección se debe a lo siguiente:

- **SO₂:** Gas contaminante que se produce por la quema de combustibles fósiles que contienen azufre, se utiliza específicamente como indicador directo de emisiones de refinerías.
- **PM₁₀:** Partículas sólidas en el aire, se utiliza como indicador de contaminación por polvo y cenizas generados en procesos de combustión y emisiones fugitivas.
- **PM_{2.5}:** Partículas pequeñas capaces de penetrar en pulmones y torrente sanguíneo, este indicador es clave de contaminación por combustión incompleta, proveniente de reacciones químicas secundarias y quemaduras.

Por estas razones se consideró utilizar estos indicadores para poder realizar los análisis, debido a que tienen una fuerte relación a nuestro objetivo.

IV. VALIDACIÓN DE SUPUESTOS REQUERIDOS

Para empezar las pruebas estadísticas elegidas, era necesaria la validación de ciertos supuestos, por lo que se realizó lo siguiente antes de poner en práctica la regresión lineal múltiple:

- **QQ plot de residuos:** Un gráfico que compara los cuantiles de los residuos observados contra los teóricos de una distribución normal. Es importante para la revisión gráfica de la normalidad de los datos; sin embargo, para este caso, los datos se acomodaron de la siguiente manera:

- **Prueba de Anderson-Darling:** Prueba estadística de bondad de ajuste, que mide la diferencia entre los datos reales y los de una distribución teórica para confirmar si los residuos pueden asumirse normales, para lo cual se necesita un valor de p mayor a 0.05.
- **Prueba de Lilliefors (KS ajustado):** Prueba de normalidad que se utiliza cuando la media y la desviación estándar de la población no son conocidas, y debe hacerse una estimación a partir de la muestra que se tiene.
- **Jarque-Bera (asimetría/curtosis):** Prueba de normalidad, evalúa si los datos tienen la simetría y la curtosis que debe tener una distribución normal, midiendo si se alejan de una curva normal.
- **Bartlett:** Prueba de homogeneidad de varianzas, en donde evalúa si varias muestras de distintos grupos comparten varianzas iguales. Esta prueba suele utilizarse antes de aplicar pruebas como el ANOVA, debido a que asumen varianzas iguales entre los grupos.
- **KMO:** Prueba de adecuación de muestreo para análisis factorial. Nos ayuda a medir qué tan apropiados son los datos y las correlaciones que hay entre las variables para poder realizar el análisis factorial. Nos dice si las variables tienen suficiente relación común.

En nuestros datos se realizaron las pruebas mencionadas anteriormente, en donde se obtuvo como resultado que los datos no presentan normalidad, teniendo un p-value ≤ 0.05 . Se realizaron 6 gráficos de QQ-Plot, cada uno correspondiendo a las pruebas de normalidad de los residuos de los modelos de regresión lineal, estos son para las zonas de Juárez y Guadalupe, para cada uno de los contaminantes, como se muestra a continuación.




Fig. 1. SO₂ - Juárez




Fig. 2. PM10 - Juárez




Fig. 5. PM10 - Guadalupe




Fig. 3. PM2.5 - Juárez




Fig. 6. PM2.5 - Guadalupe




Fig. 4. SO2 - Guadalupe

V. RESULTADOS DE LOS MODELOS

Comenzando con la regresión lineal múltiple, cada uno de los modelos hechos (uno para SO₂, PM₁₀ y PM_{2.5}), mostró un buen ajuste global, con coeficientes de determinación de 0.88, 0.89 y 0.75, respectivamente, lo cual es un buen resultado, ya que sugiere que, entre el 75% y 89% de la variabilidad de las concentraciones puede explicarse por el resto de las variables de los datos proporcionados.

Ahora, particularmente para SO₂, se observa como el componente de zona del viento (wind_u), tuvo un efecto significativo con un valor de 0.066, lo que significa que la dirección y velocidad del viento son importantes en la dispersión de este gas. Por otro lado, para PM₁₀, se destacaron la radiación solar y la dirección del viento (SR y WDR), con valores de p de aproximadamente 0.05, lo que da evidencia de la influencia meteorológica directa cuando se trata del movimiento de estas partículas contaminantes. Finalmente, para PM_{2.5} pasó algo interesante, ya que el modelo presenta menor capacidad explicativa, con una r^2 de 0.75, lo que pudiera interpretarse como que este contaminante no se afecta tanto por las variables tomadas en cuenta por el modelo, sino por aspectos externos como el transporte vehicular.

Además, el análisis factorial presentó a las variables meteorológicas y los contaminantes agrupados en factores, representando distintos procesos atmosféricos, pero son relevantes en este caso el que agrupa a SO₂, NO₂ y a CO en un factor de contaminación industrial, en conjunto con el que agrupa temperatura, radiación y al viento, en otro factor. Esto refuerza los resultados anteriores, ya que presenta que la refinería de Cadereyta como fuerte proveedor de contaminantes, lo cual solo aumenta con las condiciones climáticas.

VI. VALIDAR LA EFICIENCIA DE LOS MODELOS

Para poner en práctica el uso de las pruebas estadísticas, se probaron ciertos supuestos que se presentan a continuación: La normalidad de los residuos se confirma por los tests de Anderson-Darling, Lilliefors y Jarque-Bera, con valores de p arriba de 0.4 en todas las ocasiones; luego, para la homocedasticidad con el test de Breusch-Pagan, solo que por el valor de p, que fue mayor a 0.24, no se pudo probar; además, el test de Durbin-Watson revisó la autocorrelación de los datos, resultó con valores de entre 1.9 y 2.8, presentando los datos aceptables para independencia de errores, esto respalda la validez y estabilidad estadística de los modelos. Por último, RMSE desplegó errores medios bajos: Para SO₂, 0.73, para PM₁₀, 0.12, y para PM_{2.5}, 0.08, indicando buena calidad de predicciones.

A. Variables más importantes

Tomando en cuenta los coeficientes y los valores t, se pueden obtener las variables más importantes dentro de las 3 variables que utilizamos para el análisis:

- SO₂: Dirección y magnitud del viento (variable wind_u), muestran influencia relevante, con un p-value = 0.066, lo cual coincide con la hipótesis de que las condiciones del viento si modulan la dispersión del contaminante desde la refinería de Cadereyta.
- PM₁₀: Variables SR (radiación solar) y la variable WDR (dirección del viento) y la variable NO fueron las más relevantes para este análisis, dando una interacción entre procesos fotoquímicos y transporte de partículas en el área.
- PM_{2.5}: No hubo predictores altamente significativos, sin embargo, las variables de presión atmosférica y humedad relativa mostraron tendencias consistentes con el comportamiento de las partículas finas, es decir, mayor concentración en condiciones estables o húmedas.

VII. CONCLUSIONES PARCIALES

Los resultados obtenidos hasta ahora pueden interpretarse, aunque no necesariamente deben ser los finales. La regresión lineal múltiple confirma que la meteorología si modula de forma significativa la dispersión de contaminantes asociados con la Refinería de Cadereyta alrededor de esta, ya que, como se mencionó, la dirección del viento y la radiación solar son directamente influyentes en sus propagaciones

hacia estaciones cercanas. Mientras que, el análisis factorial refuerza y respalda la existencia de patrones conjuntos entre variables meteorológicas y contaminantes relacionados con la industria de la zona, lo que indica que la Refinería contribuye a picos de concentración, y que esto aumenta bajo específicas condiciones climáticas.

Para la entrega final, hay varios caminos que se podrían tomar para mejorar o redireccionar el análisis, como ampliar el periodo temporal, que por el momento solo es una semana, hacía varias semanas; por otro lado, se podrían aplicar series de tiempo para analizar dependencias temporales; o incluso relacionar los factores del análisis factorial a ciertos periodos de tiempo con episodios críticos del aire para fortalecer la interpretación ambiental.

VIII. ANEXOS

Código R.
GitHub.

REFERENCES

- [1] Sistema Integral de Monitoreo Ambiental [SIMA] Nuevo León. (s/f). Gob.mx. Recuperado el 2 de octubre de 2025, de <https://aire.nl.gob.mx/>
- [2] Calidad del aire ambiente (exterior) y salud. (s/f). Who.int. Recuperado el 2 de octubre de 2025, de [https://www.who.int/es/news-room/fact-sheets/detail/ambient-\(outdoor\)-air-quality-and-health](https://www.who.int/es/news-room/fact-sheets/detail/ambient-(outdoor)-air-quality-and-health)
- [3] Ortega, C. (2021, November 19). Análisis factorial: Qué es y tipos que existen. QuestionPro. <https://www.questionpro.com/blog/es/analisis-factorial/>
- [4] Berumen. (2024, July 12). ¿Qué es y para qué sirve el análisis factorial? Berumen. <https://berumen.com.mx/que-es-el-analisis-factorial/>